

Disetujui oleh:	Disetujui oleh:
Prof. Dr. Yeni Herdiyeni, S.Si, M.kom.	Prof. Dr. Ir. Indra Jaya, M.Sc.



KOLOKIU
PROGRAM STUDI SARJANA ILMU KOMPUTER
DEPARTEMEN ILMU KOMPUTER
INSTITUT PERTANIAN BOGOR

Nama	: Tita Madriyanti
NIM	: G6401211120
Program Studi	: Sarjana Ilmu Komputer
Judul Penelitian	: Penerapan Model LSTM untuk Deteksi dan Validasi Upwelling di WPP 572 Berdasarkan Data SST dan Chl-a
Pembimbing	: 1. Prof. Dr. Yeni Herdiyeni, S.Si, M.kom. 2. Prof. Dr. Ir. Indra Jaya, M.Sc.
Hari / Tanggal	: Senin / 20 Januari 2025
Waktu	: 13.00 s/d 13.30 WIB
Tempat	: Zoom Meeting
Pembahas	: 1. Viragita Athaya Haura: G6401211116 2. Jihan Febriharvianti Wirawan: G6401211037 3. Halida Fiadnin: G6401211142

PENERAPAN MODEL LSTM UNTUK DETEKSI DAN VALIDASI UPWELLING DI WPP 572 BERDASARKAN DATA SST DAN CHL-a

Tita Madriyanti¹, Yeni Herdiyeni², Indra Jaya³

¹Mahasiswa Sarjana Program Studi Ilmu Komputer, IPB

²Pembimbing 1, staf pengajar Departemen Ilmu Komputer IPB

³Pembimbing 2, staf pengajar Departemen Manajemen IPB

Abstrak

TITA MADRIYANTI. Penerapan Model LSTM untuk Deteksi dan Validasi Upwelling di WPP 572 Berdasarkan Data SST dan Chl-a, *Application of LSTM Model for Upwelling Detection and Validation in WPP 572 Based on Sea Surface Temperature and Chlorophyll-a Concentration Data*. Dibimbing oleh YENI HERDIYENI dan INDRA JAYA.

Negara Indonesia merupakan negara kepulauan terbesar di dunia, memiliki kekayaan kelautan yang luar biasa, khususnya dalam sektor perikanan. Wilayah Pengelolaan Perikanan (WPP) 572 yang terletak di Samudra Hindia dan Selat Sunda. Salah satu fenomena oseanografi utama yang memengaruhi dinamika perikanan di wilayah ini adalah *upwelling*, yang meningkatkan konsentrasi *Chlorophyll-a* (Chl-a) dan mendukung keberadaan ikan pelagis besar seperti tuna. Fenomena ini dipengaruhi oleh kondisi lingkungan seperti suhu permukaan laut (SST) dan salinitas, serta mekanisme angin muson tenggara yang memicu Ekman pumping. Studi ini bertujuan untuk mengembangkan model *Long Short-Term Memory* (LSTM) guna mendeteksi fenomena *upwelling* di WPP 572 menggunakan data SST dan Chl-a, serta memvalidasi hasil deteksi dengan pendekatan *time-window* dan metode *Interquartile Range* (IQR). Penelitian ini difokuskan pada analisis data spasial dan temporal dari tahun 2007 hingga 2017. Kombinasi pendekatan *time-window* dan IQR memungkinkan deteksi yang lebih akurat terhadap pola temporal *upwelling*, memberikan wawasan tentang hubungan pola *upwelling* dengan dinamika oseanografi, serta mendukung pengelolaan sumber daya perikanan secara berkelanjutan. Penelitian ini memberikan manfaat sebagai referensi ilmiah dalam pengembangan teknologi berbasis *deep learning* untuk deteksi fenomena oseanografi di perairan tropis.

Kata Kunci: CHL-a, Deteksi, *Long Short-Term Memory*, SST, *upwelling*, WPP-NRI 572

I. PENDAHULUAN

1.1 Latar Belakang

Indonesia merupakan negara kepulauan terbesar di dunia, memiliki kekayaan sumber daya kelautan yang sangat melimpah. Secara geografis, Indonesia terletak antara 6° LU hingga 11° LS dan 92° hingga 142° BT, dengan sebagian besar wilayahnya terdiri dari sekitar 17.504 pulau besar dan kecil. Sekitar tiga perempat dari wilayah Indonesia merupakan wilayah perairan yang mencakup luas sekitar 5,9 juta km², dengan garis pantai sepanjang 95.161 km (Arianto 2020). Pada Deklarasi Djuanda, 13 Desember 1957, Indonesia diakui oleh komunitas internasional sebagai negara kepulauan atau "*Archipelagic State*". Pengakuan ini menjadi kekuatan utama bagi visi dan cita-cita bangsa yang menjadikan wilayah perairan sebagai sumber utama potensi kekayaan alam Indonesia (Nikawanti dan Aca 2021).

Sumber daya kelautan, terutama ikan, merupakan salah satu sumber utama ketahanan pangan di Indonesia. Produksi perikanan tangkap pada semester I tahun 2024 tercatat mencapai 3,34 juta ton, dari total potensi produksi sekitar 6 juta ton per tahun. Sebagian besar hasil ini berasal dari perairan laut, termasuk Wilayah Pengelolaan Perikanan 572 (WPP-NRI-572), yang mencakup perairan Samudra Hindia di barat Sumatra dan Selat Sunda. Wilayah ini dikenal memiliki aktivitas penangkapan ikan yang tinggi, terutama untuk jenis ikan pelagis besar seperti tuna, tongkol, dan cakalang. Ketiga spesies ini menjadi komoditas utama yang mendukung pasar perikanan global dengan hasil tangkapan mencapai 164,8 ribu ton per tahun (Kementerian Kelautan dan Perikanan 2024; Simbolon et al. 2024).

Tuna salah satu ikan pelagis besar dari *family Scombridae* yang dikenal sebagai ikan migrasi dengan daya renang tinggi (*high migratory species*). Tuna terdiri dari 2 subgenus dan 8 spesies yang tersebar di laut tropis, termasuk Samudra Hindia. Indonesia memiliki sumber daya tuna di seluruh perairan, termasuk Zona Ekonomi Eksklusif (ZEE). Wilayah distribusinya meliputi Laut Banda, Laut Maluku, Laut Sulawesi, dan Samudra Hindia. Pada 2017, produksi tuna Indonesia dari Samudra Hindia mencapai 165.725 ton, terdiri atas *albacore*, *bigeye*, *yellowfin*, dan *skipjack*. WPP 572 berada di bawah pengelolaan *Indian Ocean Tuna Commission* (IOTC), mencakup tiga jenis tuna utama, yaitu *yellowfin*, *albacore*, dan *bigeye*. Namun, pemanfaatan sumber daya tuna di WPP 572 dinilai belum optimal (Suyasa et al. 2020). Samudra Hindia menghadapi tantangan berupa keterbatasan pengetahuan dalam menentukan lokasi penangkapan ikan yang tepat karna kurangnya informasi tentang sebaran daerah penangkapan berpotensi menyebabkan *overfishing*. (Siregar et al. 2018).

WPP 572 mencakup perairan laut dalam di sekitar Aceh Barat, Sumatra Utara, Sumatra Barat, dan Bengkulu. Lokasi ini merupakan pusat aktivitas penangkapan *yellowfin* tuna dan cakalang, terutama selama musim migrasi ikan yang dipengaruhi oleh arus laut dan suhu perairan yang dapat menaikkan klorofil-a (Fauziyah et al. 2018). Berdasarkan penelitian Febryanti (2023), WPP-NRI 572 khususnya wilayah perairan Sumatera Barat memiliki karakteristik perairan tropis yang hangat, di mana sinar matahari menyinari secara merata dan curah hujan yang relatif tinggi sepanjang tahun juga menjadi ciri khas perairan di sekitar sana. Suhu permukaan laut (SST) berkisar antara 28°C hingga 30,93°C pada musim peralihan I (Maret–Mei). Suhu ini mendukung potensi penangkapan *yellowfin*

tuna (Ikan Tuna Siri Kuning), yang umumnya ditemukan pada suhu 18°C hingga 31°C. Perairan ini memiliki potensi tinggi sebagai lokasi *fishing ground yellowfin tuna*, didukung oleh ekosistem laut sebagai distribusi berbagai spesies ikan dan organisme laut lainnya. Tiupan angin muson tenggara yang intensif selama musim timur (Juni-September) memicu *upwelling* dengan mekanisme Ekman pumping, yaitu pengisian massa air permukaan yang terdorong menjauh dari pantai oleh massa air dari lapisan dalam (Amri *et al.* 2013).

Melimpahnya sumber daya perikanan di wilayah tersebut tidak terlepas dari peran *upwelling*, yaitu fenomena naiknya massa air yang kaya nutrisi, memiliki suhu lebih dingin dan bersalinitas tinggi dari lapisan bawah ke permukaan laut. Proses ini meningkatkan konsentrasi *chlorophyll-a* (Chl-a), komponen utama fitoplankton yang menjadi dasar rantai makanan di ekosistem laut. Konsentrasi tertinggi Chl-a sering ditemukan di bawah zona eufotik, yaitu lapisan laut dengan intensitas cahaya yang cukup untuk fotosintesis. Zona eufotik menerima cahaya matahari sekitar 1% dari intensitas di permukaan, yang mendukung keseimbangan antara fotosintesis dan respirasi (Supriyadi dan Hidayat 2020). Studi terkini menunjukkan bahwa *upwelling* mempengaruhi perilaku pergerakan ikan, terutama dalam pencarian sumber makanan dan habitat yang sesuai (Pratiwi 2022).

Long Short-Term Memory (LSTM) adalah jaringan saraf tiruan yang dirancang untuk analisis data deret waktu, termasuk deteksi fenomena oseanografi seperti *upwelling*. Dalam deteksi *upwelling*, model LSTM menggunakan pendekatan *time-window*, yaitu segmen data berurutan dengan panjang tetap, untuk menangkap pola temporal dari data Suhu Permukaan Laut (SST) dan konsentrasi klorofil-a (Chl-a) (Banoula 2023). Pendekatan ini meningkatkan akurasi deteksi pola perubahan dalam fenomena oseanografi (Contractor & Roughan 2021). Digunakan juga metode seperti *Interquartile Range* (IQR) untuk memastikan kualitas data dan menghilangkan outlier, seperti lonjakan tiba-tiba Chl-a selama periode *upwelling* intens (Anandari *et al.* 2024; García-Seoane *et al.* 2023). Kombinasi pendekatan *time-window* dan penanganan outlier memungkinkan model LSTM mendeteksi pola *upwelling* secara lebih akurat, mendukung analisis fenomena oseanografi di perairan tropis.

1.2 Perumusan Masalah

- 1.2.1 Bagaimana fenomena *upwelling* dapat dideteksi dan divalidasi di WPP 572 menggunakan data Suhu Permukaan Laut (SST) dan konsentrasi klorofil-a (Chl-a) dalam mengoptimalkan sumber daya perikanan?
- 1.2.2 Bagaimana model *Long Short-Term Memory* (LSTM) dapat diterapkan untuk mendeteksi pola temporal *upwelling* secara akurat di WPP 572?
- 1.2.3 Bagaimana efektivitas pendekatan *time-window* dan metode *Interquartile Range* (IQR) dalam mendukung validasi hasil deteksi *upwelling*?

1.3 Tujuan

- 1.3.1 Mengembangkan model LSTM untuk mendeteksi fenomena *upwelling* di WPP 572 berdasarkan data SST dan Chl-a.

- 1.3.2 Memvalidasi hasil deteksi *upwelling* menggunakan pendekatan *time-window* dan metode IQR.
- 1.3.3 Menganalisis dan memberikan wawasan tentang hubungan antara pola *upwelling* dan dinamika oseanografi di WPP 572.

1.4 Manfaat

- 1.4.1 Menyediakan referensi ilmiah untuk pengembangan metode deteksi dan validasi *upwelling* menggunakan teknologi berbasis *Deep Learning*.
- 1.4.2 Memahami pengaruh fenomena *upwelling* terhadap ekosistem laut, khususnya di perairan tropis WPP 572.
- 1.4.3 Mendukung pengelolaan sumber daya perikanan yang berkelanjutan dengan informasi yang akurat tentang lokasi dan waktu *upwelling*.

1.5 Ruang Lingkup

- 1.5.1 Wilayah pengelolaan perikanan WPP-RI 572 di Samudra Hindia dan Selat Sunda, khususnya pada daerah yang memiliki potensi perikanan tinggi.
- 1.5.2 Menggunakan data Suhu Permukaan Laut (SST) dan konsentrasi klorofil-a (Chl-a) dari tahun 2007 hingga 2017.
- 1.5.3 Implementasi model LSTM dengan pendekatan *time-window* untuk deteksi *upwelling* dan validasi hasil menggunakan metode IQR.
- 1.5.4 Analisis spasial dan temporal menggunakan data suhu permukaan laut (SST) dan konsentrasi klorofil-a (Chl-a), dengan pendekatan *time-window* untuk memahami pola perubahan kedua parameter tersebut.
- 1.5.5 Fokus penelitian pada deteksi dan validasi *upwelling*, tanpa mencakup prediksi jangka panjang atau analisis fenomena oseanografi lainnya

II. METODE

2.1 Data Penelitian

Data penelitian yang digunakan dalam penelitian ini diperoleh dari *Marine Copernicus*, yang menyediakan data oseanografi berkualitas tinggi untuk berbagai parameter kelautan. Variabel yang digunakan yaitu suhu permukaan laut (SST) dan konsentrasi klorofil-a (Chl-a) dengan rentang waktu 2007-2017. Data ini mencakup wilayah Samudra Hindia, khususnya area yang relevan dengan penelitian mengenai fenomena *upwelling* di WPP-NRI 572. Data yang tersedia dari *Marine Copernicus* memiliki resolusi spasial dan temporal yang cukup tinggi, sehingga memungkinkan analisis mendalam terhadap pola-pola perubahan dalam SST dan Chl-a seiring waktu.

Tabel 1 Dataset suhu dan klorofil-a

Parameter	Data	Product Dataset	Sumber Data	Depth Level	Resolusi	
					Spasial	Temporal
<i>Physic</i>	<i>SST (Sea surface foundation temperature)</i>	<i>Global Ocean OSTIA Sea Surface Temperature and Sea Ice Analysis</i>	https://data.marine.copernicus.eu/product/SST_GLO_ST_L4_NRT_OBSERVATIONS_010_001/download	0 m	5.5 x 5.5 km	<i>Daily</i>
<i>BioChem</i>	<i>Chlorophyll-a (Mass concentration of chlorophyll a in sea water)</i>	<i>Colour (Copernicus-GlobColour), Bio-Geo-Chemical, L4 (monthly and interpolated) from Satellite Observations (1997-on going)</i>	https://data.marine.copernicus.eu/log/in?redirect=%2Fproduct%2FOCEANCOLOUR_GLOBAL_MONTHLY_009_104%2Fdownload	0 m	4 x 4 km	<i>Daily</i>

2.2 Peralatan Penelitian

Penelitian ini dilakukan menggunakan perangkat keras dan perangkat lunak sebagai berikut:

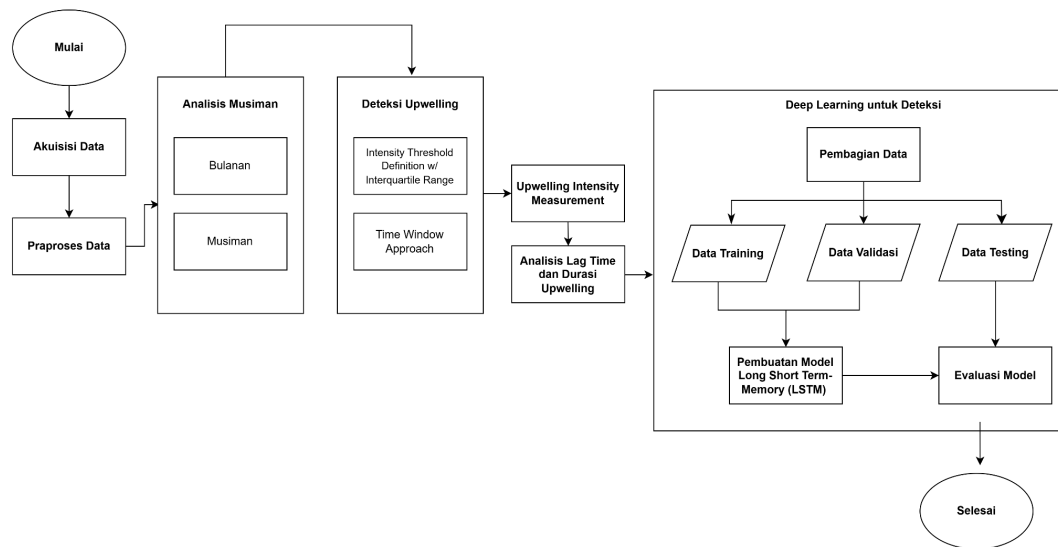
- 1 Perangkat keras berupa komputer dengan spesifikasi:
 - Laptop HP Intel CORE i7 11th Gen
 - RAM 8 GB, SSD 256
- 2 Perangkat lunak yang digunakan antara lain:
 - Server Komputasi GPU
 - Jupyter Notebook G3
 - Sistem Operasi Windows 11 x64 bit sebagai sistem operasi

- Terminal Miniforge
- Draw.io untuk menggambar diagram-diagram
- Bahasa Pemrograman Python

2.3 Tahapan Penelitian

Penelitian ini dilakukan dengan beberapa tahap, dimulai dari pengumpulan data, pra-proses data, analisis musiman, algoritma deteksi *upwelling*, analisis lag time dan durasi *upwelling*, pembangunan model LSTM untuk deteksi serta evaluasi model. Diagram tahapan penelitian dapat dilihat pada gambar di bawah ini.

Tabel 2 Diagram tahapan penelitian



2.3.1 Pengumpulan Data

Pengumpulan data dilakukan dengan mengunduh data pada platform *Marine Copernicus*. Berikut data yang diunduh berupa:

1. Location WPP 572: 94°BT - 110°BT dan 10°S - 6°LU. WPP 572 mencakup area Samudera Hindia sebelah Barat Sumatera dan Selat Sunda. Wilayah ini meliputi area 6 provinsi yaitu Nangroe Aceh Darussalam, Sumatera Utara, Sumatera Barat, Bengkulu, Lampung, dan Banten.
2. Time: 2007-2017
3. Level (depth): level 1-14 (0-25 m)
4. Variabel (SST dan Chl-a)

Dikarenakan ukuran data yang besar sehingga dapat diakses melalui terminal miniforge.

1. Buka Miniforge
2. activate dengan perintah `env → (base) C:\Users\HP → mamba activate mandachr`
3. Buka folder cmems yang telah dibuat → `cd Copernicus_Marine`
4. Aktifkan paket yang diperlukan dengan perintah → `(mandachr) C:\Users\LENOVO\Marine_Copernicus → conda activate cmt_1.0`

5. Drop link yang didapatkan dari Marine Copernicus.

2.3.2 Pra-Proses Data

Tahap pra-proses data merupakan langkah awal penting dalam menyiapkan data sebelum pelatihan model. Proses ini mencakup penanganan data yang hilang (*missing values*) dengan metode seperti menghitung rata-rata nilai atribut dalam kelas yang sama untuk menjaga kualitas data. Selain itu, normalisasi data dilakukan untuk memastikan semua fitur berada dalam skala yang seragam, hal ini karna model *Long Short-Term Memory* (LSTM) sensitif terhadap perbedaan skala antar fitur. Metode *MinMaxScaler* digunakan untuk menormalkan data, mengubah skala nilai ke rentang tertentu sehingga meningkatkan konsistensi dan kinerja model (Toyib *et al.* 2024). Normalisasi ini memungkinkan model untuk bekerja lebih efektif untuk meningkatkan akurasi dan stabilitas dalam mendeteksi fenomena *upwelling* berdasarkan data suhu permukaan laut (SST) dan konsentrasi klorofil-a (Chl-a).

$$X' = \frac{X - X_{min}}{X_{max} - X_{min}}$$

Dimana:

- X' nilai yang telah dinormalisasi
- X nilai asli dari data
- X_{min} nilai minimum dalam dataset
- X_{max} nilai maksimum dalam dataset

2.3.3 Analisis Data Bulanan dan Musiman

1. Analisis Bulanan Suhu Permukaan Laut (SST) dan Klorofil-a (Chl-a)

Pada tahap analisis bulanan, dilakukan perhitungan statistik deskriptif untuk menentukan nilai rata-rata, median, maksimum, minimum, dan standar deviasi dari suhu permukaan laut (SST) dan konsentrasi klorofil-a (Chl-a) setiap bulan. Analisis ini bertujuan untuk mendeteksi variasi bulanan dalam kondisi oseanografi yang memengaruhi fenomena *upwelling*. Variasi ini memberikan wawasan tentang bulan-bulan tertentu di mana intensitas *upwelling* mungkin lebih tinggi atau rendah, serta dampaknya terhadap ketersediaan nutrisi di laut. Seperti terdapat bulan-bulan dengan SST yang lebih tinggi dapat mengindikasikan peningkatan aktivitas *upwelling*, yang berdampak pada peningkatan konsentrasi klorofil-a dan produktivitas ekosistem laut di WPP 572. Analisis ini penting untuk mendeteksi pola fluktuasi jangka pendek dalam SST dan Chl-a yang dapat mempengaruhi ekosistem perikanan lokal (Anandari *et al.* 2024).

2. Analisis Musiman Suhu Permukaan Laut (SST) dan Klorofil-a (Chl-a)

Analisis musiman dilakukan dengan membagi tahun menjadi empat musim berdasarkan sistem musim Boreal: Musim Boreal Spring, Musim Boreal Summer, Musim Boreal Autumn, dan Musim Boreal Winter. Setiap musim ini berhubungan dengan perubahan iklim dan angin yang dapat memengaruhi dinamika *upwelling* di wilayah WPP 572. Analisis SST dan Chl-a pada setiap musim memungkinkan deteksi pola musiman yang lebih luas, seperti peningkatan *upwelling* yang sering terjadi pada Musim Boreal Spring dan Summer, di mana suhu permukaan laut lebih tinggi dan angin muson bergerak mengarah ke laut (Amri *et al.* 2013). Musim-musim ini dapat memicu peningkatan konsentrasi klorofil dan ketersediaan nutrisi yang mendukung produktivitas ekosistem laut dan perikanan di WPP 572. Pada analisis musiman, pola SST dan Chl-a dapat mengungkapkan hubungan antara fenomena *upwelling* dan proses iklim global yang lebih besar, seperti *El Niño-Southern Oscillation* (ENSO), yang mempengaruhi pola musiman di WPP 572. Oleh karena itu, analisis musiman ini penting untuk mendeteksi intensitas *upwelling* pada periode-periode tertentu, serta dampaknya terhadap ekosistem dan sumber daya perikanan di wilayah tersebut (Anandari *et al.* 2024).

2.3.4 Deteksi Upwelling

Pada tahap ini, dilakukan penentuan intensitas dengan (IQR). Dalam mendeteksi pola *upwelling*, langkah awal yang dilakukan adalah menentukan batas intensitas fenomena ini. Batas ini dihitung menggunakan teknik statistik yaitu *Interkuartil Range* (IQR) untuk mengatasi data pencilan (*outliers*) yang bisa mengganggu analisis. Menghitung nilai kuartil pertama (Q1) dan kuartil ketiga (Q3), kemudian menghitung dengan rumus sebagai berikut (García-Seoane *et al.* 2023).

$$IQR = Q3 - Q1$$

Batas pencilan dihitung menggunakan rumus berikut.

$$Lower\ Bound = Q1 - 1.5 \times IQR$$

$$Upper\ Bound = Q3 + 1.5 \times IQR$$

Data yang berada di luar rentang *Lower Bound* dan *Upper Bound* dianggap sebagai outlier dan dikeluarkan dari analisis. Proses ini memastikan bahwa data yang digunakan untuk memodelkan fenomena *upwelling* bebas dari nilai ekstrem yang dapat menyebabkan bias.

Pendekatan *time window* digunakan untuk membagi data menjadi interval waktu tertentu, seperti bulanan atau tahunan. Proses ini bertujuan untuk mendeteksi pola temporal yang terkait dengan fenomena *upwelling* secara lebih akurat, termasuk perubahan musiman atau tren jangka pendek. Dengan membagi data ke dalam segmen waktu yang lebih kecil, model dapat fokus pada analisis perubahan dalam periode tertentu. Pendekatan ini dikombinasikan dengan analisis

spasial untuk mengidentifikasi pola distribusi fenomena *upwelling* di wilayah geografis tertentu. Data dari Wilayah Pengelolaan Perikanan (WPP) 572, wilayah dikelompokkan berdasarkan lokasi seperti barat, tengah, dan timur. Pembagian ini mempertimbangkan karakteristik oseanografi lokal. Melalui kombinasi pendekatan temporal dan spasial, model mampu mengenali pola intensitas, durasi, dan distribusi *upwelling* secara lebih mendalam.

2.3.5 Pengukuran Intensitas Upwelling

Dalam memahami dampak fenomena *upwelling* terhadap ekosistem laut di WPP 572, pengukuran intensitas *upwelling* sangat penting, karena peristiwa dengan intensitas tinggi membawa lebih banyak nutrisi ke permukaan laut, yang mendukung pertumbuhan fitoplankton dan meningkatkan kelimpahan ikan. Pengukuran intensitas ini memungkinkan penilaian yang lebih akurat terhadap produktivitas ekosistem dan kelimpahan ikan di wilayah tersebut. Variabilitas intensitas *upwelling* dapat berbeda secara musiman dan antar-tahunan. Hal ini juga dipengaruhi oleh fenomena iklim besar seperti *El Niño-Southern Oscillation* (ENSO). *Upwelling* yang lebih kuat biasanya menghasilkan respons klorofil yang lebih cepat, memperpendek waktu antara suhu permukaan laut yang rendah dan konsentrasi klorofil yang tinggi, serta memperpanjang periode produktivitas biologis.

Dalam penelitian ini, intensitas *upwelling* dihitung berdasarkan puncak konsentrasi klorofil selama peristiwa *upwelling*, dengan ambang batas intensitas yang ditetapkan menggunakan kuantil klorofil, intensitas rendah pada persentil ke-94, tinggi pada persentil ke-98, dan sedang di antara keduanya. Metode ini membantu mengidentifikasi peningkatan produktivitas biologis selama peristiwa *upwelling* di WPP 572.

2.3.6 Analisis waktu tunda (*lag time*) dan durasi upwelling

Analisis waktu tunda (*lag time*) dan durasi *upwelling* dilakukan untuk memahami hubungan temporal antara variabel oseanografi, seperti suhu permukaan laut (SST) dan konsentrasi *Chlorophyll-a* (Chl-a) melalui fenomena *upwelling*. *Lag time* dihitung untuk menentukan durasi antara perubahan parameter oseanografi, seperti penurunan suhu atau peningkatan klorofil. Durasi *upwelling* dianalisis sebagai interval waktu antara awal dan akhir peristiwa, ini ditentukan berdasarkan ambang batas perubahan parameter seperti penurunan suhu di bawah rata-rata musiman dan kembalinya ke kondisi normal.

2.3.7 Long Short-Term Memory untuk Deteksi Upwelling

Sebelum melakukan deteksi fenomena *upwelling* menggunakan model *Long Short-Term Memory* (LSTM), data dibagi menjadi tiga bagian:

- **Data Training:** Digunakan untuk melatih model agar dapat mengenali pola dan mendeteksi fenomena *upwelling*. Porsi data terbesar, sekitar 70-80%, dialokasikan untuk pelatihan.
- **Data Validation:** Digunakan untuk menyesuaikan parameter model dan meminimalkan kesalahan selama pelatihan, seperti menentukan jumlah *epoch* yang tepat agar tidak terjadi *overfitting*. Porsi data ini biasanya sekitar 10-15%.
- **Data Testing:** Digunakan untuk mengukur akurasi model dan memastikan model dapat diterapkan pada data yang belum pernah dilihat sebelumnya, biasanya sekitar 10-15%.

Model *Long Short-Term Memory* (LSTM) digunakan untuk menganalisis data deret waktu, seperti variasi musiman atau anomali yang terkait dengan *upwelling*. Pendekatan ini memastikan model mampu mendeteksi intensitas dan durasi fenomena *upwelling* dengan tingkat akurasi yang tinggi (Fredyan 2020).

2.3.8 Evaluasi Model

Setelah model dilatih dan diuji, dilakukan evaluasi model untuk mengukur seberapa baik model dapat mendeteksi fenomena *upwelling* dengan menggunakan klasifikasi. Model LSTM yang digunakan untuk mendeteksi *upwelling* dievaluasi menggunakan metrik klasifikasi seperti di bawah ini (Putri *et al.* 2022).

1. *Accuracy* (Akurasi): Menghitung rasio kejadian yang terdeteksi dengan benar terhadap jumlah total sampel yang dievaluasi, baik untuk deteksi *upwelling* maupun *non-upwelling*.

$$Accuracy = \frac{TP}{TP+TN+FP+FN}$$

Di mana :

- *TP* adalah *True Positives*
- *TN* adalah *True Negative*
- *FP* adalah *False Positives*
- *FN* adalah *False Negative*

2. *Precision* (Ketepatan): *Precision* tinggi menunjukkan model jarang membuat kesalahan dalam mendeteksi *upwelling*.

$$Precision = \frac{TP}{TP+FP}$$

Di mana *TP* adalah *True Positives* dan *FP* adalah *False Positives*.

3. Sensitivitas atau *Recall*: Mengukur kemampuan model untuk mendeteksi semua kejadian *upwelling* yang sebenarnya, yaitu seberapa banyak kejadian *upwelling* yang terdeteksi dengan benar.

$$Recall = \frac{TP}{TP+FN}$$

Di mana *FN* adalah *False Negatives*.

4. *F1-Score* adalah harmonisasi antara *precision* dan *recall* untuk memberikan gambaran yang seimbang, terutama jika terdapat ketidakseimbangan data antara *upwelling* dan *non-upwelling*.

$$F1 - Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Jadwal Penelitian

Penelitian dijadwalkan mulai Oktober 2024 dan berakhir Mei 2025. Rinciannya dapat dilihat pada Tabel 1.

Tabel 3 Jadwal penelitian

Kegiatan	Tahun/Bulan							
	2024		2025					
	Okt	Nov	Des	Jan	Feb	Mar	Apr	Mei
Studi Literatur								
Pengumpulan data								
Pra-proses data								
Analisis Data Bulanan dan Musiman								
Deteksi Upwelling								
Pengukuran Intensitas Upwelling								
Analisis Lag Time dan Durasi Upwelling								
Penerapan Model LSTM untuk Deteksi								
Evaluasi Model								
Penulisan laporan tugas akhir								
Seminar hasil								
Revisi tugas akhir								
Sidang								

DAFTAR PUSTAKA

- Amri K, Manurung D, Gaol JL, Baskoro MS. 2013. Karakteristik suhu permukaan laut dan kejadian upwelling fase indian ocean dipole mode positif di barat sumatera dan selatan Jawa Barat. *Jurnal Segara*. 9(1): 23-35.
- Anandari AA, Harsono G, Wajdi AF. 2024. Long Short-Term Memory Recurrent Neural Network (LSTM-RNN) Aplikasi Penginderaan Jauh untuk Kelautan & Perikanan Laut Tangkap. CV Jejak (Jejak Publisher).
- Arianto MF. 2020. Potensi wilayah pesisir di negara Indonesia. *Jurnal Geografi*. 10(1): 204-215.
- Banoula M. 2023. Introduction to Long Short-Term Memory(LSTM) Last updated on 27 April 2023 (artikel).
- Contractor S, Roughan M. 2021. Efficacy of Feedforward and LSTM Neural Networks at predicting and gap filling coastal ocean timeseries: Oxygen, nutrients, and temperature. *Frontiers in Marine Science*. 8: 637759.
- Daulay SR, Sari TEY, Usman U, Jhonnerie R. 2019. Characteristics of thermal front in the tropical waters of Eastern Indian Ocean. *Jurnal Perikanan Universitas Gadjah Mada*. 21(1): 25-29. doi: <https://doi.org/10.22146/jfs.39724>.
- Fauziyah, Priatna A, Prakoso WF, Hidayat T, Surbakti H, Nurjuliasti E. 2018. Measurement and analysis of acoustic backscattering strength for characteristics of seafloor sediment in Indian Ocean WPP 572-573. *In IOP Conference Series: Earth and Environmental Science*. 162(1): 1-11.
- Febryanti HR. 2023. Pendugaan Potensi Lokasi Fishing Ground Ikan Tuna Sirip Kuning (*Thunnus albacares*) Berdasarkan Parameter Oseanografi Dengan Sistem Informasi Geografis di WPP-NRI 572: Perairan Sumatera Barat (Doctoral dissertation, UNIVERSITAS JAMBI).
- Fredyan R. 2020. Prediksi Suhu Maksimum Permukaan Darat Di Jawa Timur Menggunakan Metode Convolutional Long Short-Term Memory (Doctoral dissertation, Universitas Brawijaya).
- García-Seoane R, Viana IG, Bode A. 2023. Seasonal upwelling influence on trophic indices of mesozooplankton in a coastal food web estimated from $\delta^{15}\text{N}$ in amino acids. *Progress in Oceanography*. 219: 103149.
- Kementrian Kelautan dan Perikanan. 2024. Lampau Target, Produksi Perikanan Tangkap Tembus 111,33% di Semester I 2024. [Online] July 27, 2024. Retrieved from: <https://kkp.go.id/news/news-detail/lampau-target-produksi-perikanan-tangkap-tembus-11133-di-semester-i-2024>.

- Nikawanti G, Aca R. 2021. Ecoliteracy: Membangun Ketahanan Pangan Dari Kekayaan Maritim Indonesia. *Jurnal Kemaritiman: Indonesian Journal of Maritime*. 2(2):149-166. doi: <https://doi.org/10.17509/ijom.v2i2.37603>.
- Nugroho AA, Haris M. 2024. ANALISIS EFEKTIVITAS TEKNIK IMPUTASI PADA LSTM UNTUK MENINGKATKAN KUALITAS DATA PADA PERAMALAN CURAH HUJAN. *Jurnal Informatika dan Rekayasa Elektronik*. 7(2): 301-311.
- Pratiwi A. 2022. Pemodelan Prediksi Tangkapan Lobster Berdasarkan Parameter Ocean-Atmosfer di Perairan Indonesia.
- Putri HM, Fadlisya F, Fuadi W. 2022. Pendeteksian Bahasa Isyarat Indonesia Secara Real-Time Menggunakan Long Short-Term Memory (LSTM). *Jurnal Teknologi Terapan and Sains 4.0*. 3(1): 663-675.
- Simbolon D, Wahyu RI, Purwangka F. 2024. PRODUKTIVITAS DAN POLA MUSIM PENANGKAPAN CAKALANG DI WILAYAH PENGELOLAAN PERIKANAN 572. *Jurnal Penelitian Perikanan Indonesia*. 30(2): 99-109.
- Siregar ESY, Siregar VP, Agus SB. 2018. Analisis Daerah Penangkapan Ikan Tuna Sirip Kuning Thunnus Albacares Di Perairan Sumatera Barat 41 Berdasarkan Model GAM. *Jurnal Ilmu dan Teknologi Kelautan Tropis*. 10(2): 501-516.
- Supriyadi E, Hidayat R. 2020. Identification of upwelling area of the western territorial waters of Indonesia from 2000 to 2017. *The Indonesian Journal of Geography*. 52(1): 105-111.
- Suyasa N, Rahardjo P, Putri DR, Widagdo A. 2020. Tuna fisheries in fisheries management area Republic of Indonesia 572. *In IOP Conference Series: Earth and Environmental Science*. 441(1). IOP Publishing.
- Toyib M, Pratama TDK, Aqil I. 2024. Prediksi Kondisi Cuaca di Kabupaten Bayuwangi Menggunakan Metode LSTM. *Scientica: Jurnal Ilmiah Sains dan Teknologi*. 2(7): 78-84.
- Zainuri M. 2019. Rekayasa dan Tingkah Laku Ikan. *ke-1. Madura (ID): UTMPress*.